김태호 / 개인 프로젝트

Tax RAG Lab

조건과 근거를 검증하는 LLM 업무 지원 서비스

온라인 개인사업자의 비용 질문에 대상·연도·쟁점이 맞는 근거를 찾아 답하는 RAG입니다. 검색 결과 검증, 대화 흐름, API 호출 비용과 요청 상태 관리를 로컬 환경에서 구현했습니다.

역할 / 제품 검토·AI 개발 지원

김태호: 제품 범위·사용 흐름 검토
Codex: 구현·검증·실험 실행 지원

LangChain · Qdrant · FastAPI
React · TypeScript · SQLite

근거 검증부터 대화와 API 구현까지

일상적인 질문 → 조건 확인 → 근거 검색·검증 → 답변



2024년 배송비 질문에 대한 실제 저장 응답입니다. 최신 데모는 저장된 결과를 재생하는 방식으로 구성했습니다.

0.667 → 1.000

Recall@5 / 필터 적용 전후 · 내부 평가 9건

11 → 7

대화 턴 합계 / 같은 4개 사례

LangChain과 서비스 로직의 역할

LangChain은 검색을 연결하고, 서비스 로직은 모델 출력·적용 조건·요청 상태를 관리



검증된 근거 → 답변 작성 → 결과·대화 저장 → 화면 표시

QdrantVectorStore의 similarity_search_with_score_by_vector에 생성·캐시한 질문 벡터를 전달합니다. 임베딩을 중복 호출하지 않고, 같은 조건에서 Qdrant 직접 검색(raw)과 결과를 비교할 수 있도록 구성했습니다.

LLM과 임베딩

Terra는 사용자 발화에서 사실과 쟁점 후보를 추출합니다. 문서와 질문에 동일한 임베딩 모델(text-embedding-3-large)과 3072차원을 사용합니다.

서비스 로직

발화와 추출값 대조, 적용 연도·범위 선택, 추가 질문, 인용 확인, 답변 문구 선택, 비용과 요청 상태를 관리합니다.

데이터 저장

Qdrant는 검색 색인을 저장합니다. SQLite는 프로필·대화·요청·비용·캐시를, 원본 JSONL은 근거 내용을 보관합니다.

단일 로컬 환경에서 구현했습니다. 기존 RAG의 근거 설명은 LLM이 생성하고, 일반 원칙을 적용하는 결론은 미리 정의한 규칙과 문구로 제공합니다. LangGraph·MCP는 사용하지 않았습니다.

질문에 맞는 근거를 고르는 방법

대상·연도·쟁점이 하나의 적용 관계로 연결되어 있는지 함께 확인

적용 조건의 조합 오류를 설명하기 위한 예시입니다. 실제 법령 데이터는 아닙니다.

예시의 적용 관계

관계 A 온라인 / 2024 / 업무 관련성

관계 B 다른 대상 / 2025 / 업무 관련성

질문: 온라인 / 2025 / 업무 관련성

값을 따로 찾으면 잘못된 조합도 허용

조합을 함께 확인하면 해당 근거는 제외

대상에 '온라인'이 있고 연도에 '2025'가 있다는 사실만 따로 확인하면, 다른 대상의 2025년 자료까지 허용할 수 있습니다.

대상·연도·쟁점 조합(tuple)에 맞는 적용 관계(binding)를 찾고, 여기에 연결된 원문(parent)만 검색 후보로 허용합니다.

01 **검색 대상 제한**

허용할 원문 ID를 metadata.parent_id의 MatchAny 필터에 전달

→ 02 **문서 단위 정렬**

검색 조각(child)을 점수·ID 순으로 정렬하고, 원문별 중복을 제거해 상위 10건 선택

→ 03 **근거·인용 검증**

적용 범위와 원문 위치·내용·출처를 확인하고, 인용이 검색 근거에 포함되는지 검사

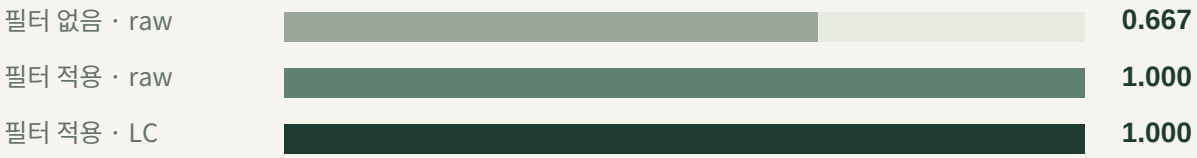
2026년 질문에는 2025년 자료를 잠정 참고합니다. 2027년 질문은 직전 연도 자료가 없어 보류하며, 질문 연도와 참조 연도를 화면에 따로 표시합니다.

검토한 포장·배송 조건에 한해 일반 원칙의 근거를 별도로 검색합니다. 범위와 인용 검증만으로 개별 거래의 세무 판단을 확정하지 않으며, 확인되지 않은 조건은 추가 검토로 남깁니다.

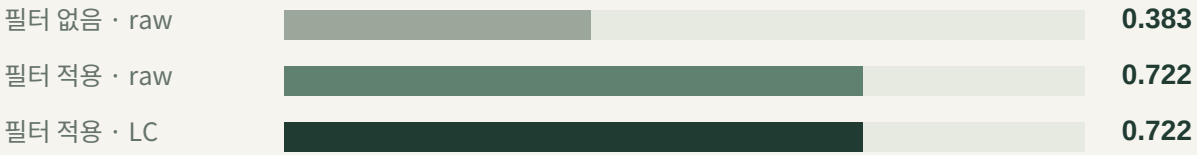
적용 범위 필터의 효과

데이터·임베딩·청킹·거리 척도·검색 건수를 고정하고 세 가지 설정을 비교

Recall@5



MRR@10



raw: Qdrant 직접 검색 / LC: LangChain / 축 0–1

같은 필터에서 결과가 일치한 문항

12 / 12

검색 지표는 적용 범위 필터를 추가한 뒤 개선됐습니다. 같은 필터를 사용하면 raw·LangChain 결과는 12건 모두 같았습니다.

문항별 검색 후보 중 범위를 벗어난 근거는 76→0건으로 줄었습니다. 후검증을 거쳐 채택한 근거의 범위 위반은 세 설정 모두 0건입니다.

검색 설정	Recall@5	MRR@10	순위 평가 / 전체
필터 없음 · raw	0.667	0.383	9 / 12
필터 적용 · raw	1.000	0.722	9 / 12
필터 적용 · LC	1.000	0.722	9 / 12

전체 12문항 중 근거가 없는 3건을 제외한 9건의 검색 순위 평가입니다. 원문을 바탕으로 만든 가상 질문이며, 전문가가 검증한 정답셋은 아닙니다. 모든 설정에서 검색 후 근거 검증을 유지했습니다. 기존 보고서를 대조한 결과입니다.

반복 질문과 불필요한 보류 개선

동일한 개발용 사례 4건을 수정 전후로 실행해 질문과 응답의 변화를 확인

배송비 사례 / 저장된 실제 질문·응답 발췌

온라인 쇼핑몰 하는 개인사업자야. 고객 주문 상품 배송하려고 2025년 9월 2일에 택배비 3만원을 내가 카드로 결제했어. 사업용 배송비인데 비용 처리 돼?

이전 · 2턴

“어떤 목적의 지출이었나요?”
“누가 결제했나요?”를 다시 묻고
추가 확인이 필요하다고 안내

개선 후 · 1턴

이미 말한 목적·결제자를 반영
“말씀하신 배송비는 사업 비용으로 처리할 수 있어요.”
일반 원칙의 근거와 적용 범위 표시

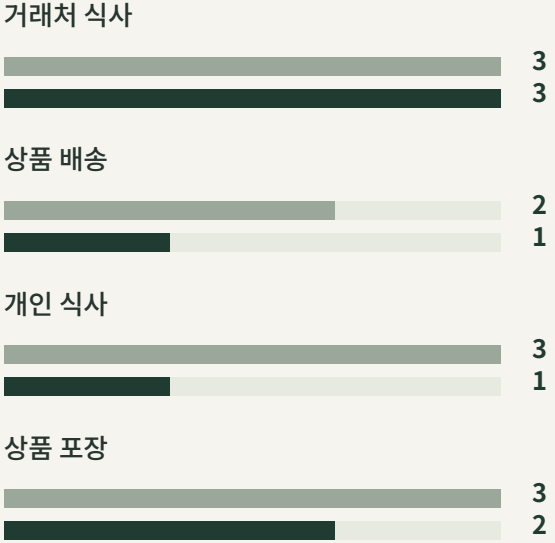
중복 질문 모델이 놓친 사실과 검증 규칙이 잘못 거부한 표현을 구분. 발화와 대조해 명시된 결제자·배송 목적을 반영.

과도한 보류 자료 부족으로 보류하던 포장·배송은 검토된 조건에서 일반 원칙의 근거를 별도로 검색하도록 보완.

문맥 오류 개인 지출은 별도 문구로 조기 안내. 거래처 식사 규칙이 직원 회식에 적용되지 않도록 조건을 좁힘.

같은 4개 사례의 대화 턴 비교

회색: 이전 녹색: 개선 후



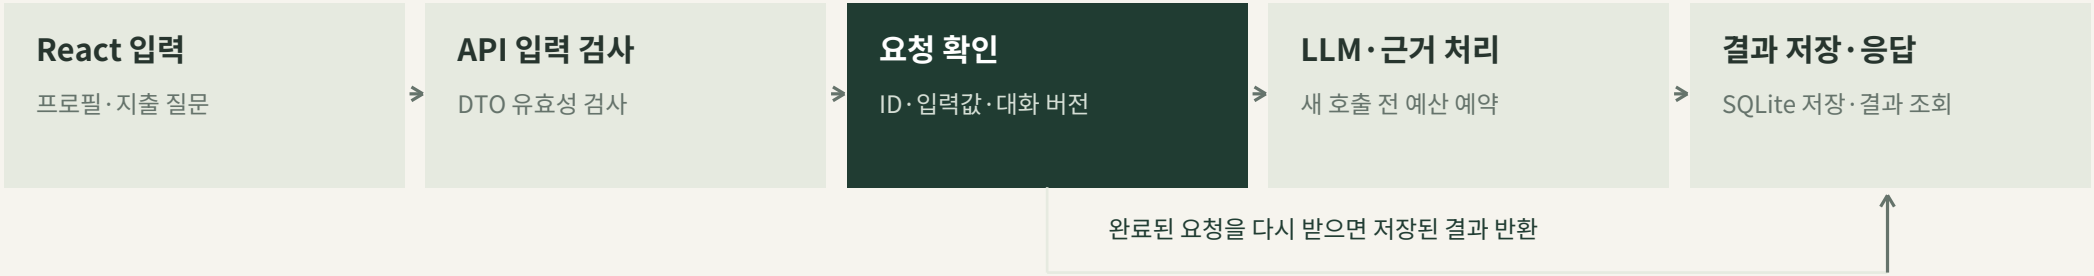
11 → 7

최종 6건: 기대 동작 6/6 일치
수정 후 같은 6건 재검사: 6/6 일치

같은 가상 지출 4건의 총 대화 턴(질문·응답 횟수)이 11→7로 줄었습니다. 후속 답변에는 구조화된 입력을 사용했습니다. 사용자 전체의 효과로 일반화하지 않으며, 같은 6건을 재검사한 결과를 독립 12건의 평가로 합산하지 않습니다.

API 요청 처리와 비용 관리

React·FastAPI를 연결하고, 요청 확인부터 결과 저장·재사용·비용 정산까지 구성



Python DTO → OpenAPI 명세 → TypeScript 타입 → 응답 형식 검사. 공통 명세와 예제로 프런트·백엔드의 데이터 형식을 맞춥니다.

프로필 CRUD와 대화 저장

공통 경로: /api/v1/chat

HTTP / 경로	동작
PUT /profile	생성·갱신
GET /profile	조회
DELETE /profile	프로필 초기화

프로필·대화·결과는 SQLite에 저장합니다. 대화 생성, 메시지 전송, 저장 결과 조회를 각각 API로 제공합니다.

새 API 호출: 비용 예약 → 호출 → 정산

01 **예약** BEGIN IMMEDIATE 트랜잭션에서 누적 예산을 확인하고 호출 금액을 예약합니다.

02 **호출** 호출은 최대 2회 시도합니다. 실패·재시도 비용도 동일한 누적 예산에 반영합니다.

03 **정산** API가 반환한 사용량으로 정산합니다. 시간 초과·사용량 미확인 시 예약액을 유지합니다.

기존 기록의 외부 API 호출 시도는 71회, 사용량으로 환산한 누적 비용은 $0.23778488입니다. 앱 시작·조회·완료된 요청의 결과 재사용에는 새 유료 호출이 없습니다. 공개 서비스 운영과 분산 환경의 동시성 검증은 수행하지 않았습니다.

프로젝트 기여와 확장 방향

직접 결정·검토한 내용과 AI 개발 도구가 지원한 작업을 구분

김태호 / 제품 범위·사용 흐름 검토

- 사용 대상·입력 방식·사용 모델·누적 예산 한도 결정
- 반복 질문의 불편을 검토하고, 질문 묶음과 빠른 선택 기능 요청
- 결론·이유·상세 근거를 보여 주는 순서와 사례별 기대 동작 검토

Codex / AI 개발 지원

- RAG·대화·API·화면·저장 기능과 테스트 코드 작성 지원
- API 호출·실패 재현·회귀 검증·비용 집계 실행 지원
- 원문 대조, 검색 비교 실험, 버전·데모·문서 정리 지원

다른 분야로의 확장 가능성

대상·연도·쟁점으로 근거를 구분한 방식을, 문서 버전·대상·업무 조건을 확인하는 다른 분야의 문서 검색에도 적용해 볼 수 있습니다. 실제 적용을 위해서는 해당 분야의 자료로 조건과 평가 기준을 먼저 검증해야 합니다.

향후 과제: 적용 조건·문서 개정 이력 정의 → 해당 분야 담당자와 평가 문항·보류 기준 검토 → 권한·비용·동시성 검증

현재 범위는 로컬 구현과 소규모 내부 평가입니다. 세무 분야 전반의 정확도 검증과 제조 현장·고객 대상 운영은 수행하지 않았습니다. LangGraph·MCP·하이브리드 검색·재순위화는 미구현입니다.